Міністерство освіти і науки України
Харківський національний університет радіоелектроніки

Звіт
з лабораторної роботи №1
з дисципліни «ТЕХНОЛОГІЇ РОЗРОБКИ ГІБРИДНИХ СИСТЕМ ШТУЧНОГО ІНТЕЛЕКТУ »

Виконала:
студентка групи ІПЗм-26-1
Трухачова Т. І.

Перевірив:
ст. викл. Дашенков Д.С.

Харків 2026

Мета та постановка завдання

Мета роботи — набуття практичних навичок попереднього проєктування програмного забезпечення для системи генерації, доповненої пошуком (Retrieval-Augmented Generation, RAG), на прикладі навчального асистента з питань штучного інтелекту (AI) та великих мовних моделей (LLM).

У межах роботи необхідно сформулювати конкретний сценарій використання, обрати та обґрунтувати корпус даних і технологічний стек, визначити склад компонентів архітектури та підготувати репозиторій GitHub.

Теоретичні відомості

RAG (Retrieval-Augmented Generation) — це підхід, який дозволяє мовній моделі формувати відповіді на основі додаткової інформації із зовнішніх джерел. Замість того щоб покладатися лише на власні знання, модель отримує знайдені документи або їхні фрагменти та використовує їх для створення відповіді з посиланнями на джерела.

Для цього документи спочатку очищують і ділять на невеликі частини — чанки. Потім модель ембедингів перетворює їх на числові вектори, які зберігаються у векторному індексі. Коли користувач ставить запитання, ретривер знаходить найбільш відповідні фрагменти документів. Мовна модель (LLM) використовує ці фрагменти для формування відповіді.

Завдання 1. Сценарій використання RAG-системи

Проєктована система — це навчальний RAG-асистент для студентів, розробників та всіх, хто вивчає штучний інтелект (AI) і великі мовні моделі (LLM). Його основне завдання — допомагати користувачам розбиратися в нових поняттях і технологіях, знаходячи інформацію у спеціально підібраних навчальних матеріалах.

Користувач може ставити запитання українською або англійською мовою, наприклад: «Чим RAG відрізняється від fine-tuning? », «Що таке ембединги та як вони використовуються в семантичному пошуку? », «У чому

різниця між encoder-only і decoder-only моделями? ». Система знаходитиме відповідну інформацію в документах, формуватиме зрозумілу відповідь і додаватиме посилання на джерела.

Основна мета асистента — не просто дати відповідь, а допомогти користувачеві зрозуміти тему та за потреби перевірити інформацію в першоджерелі. Якщо користувач просить порівняти кілька технологій, система має пояснити їхні основні відмінності, переваги та обмеження. Якщо в документах недостатньо інформації для відповіді, асистент повинен повідомити про це, а не вигадувати факти.

Типові запитання користувача

Користувачі AI Concept Explorer можуть звертатися до асистента з різними запитаннями, пов'язаними з вивченням штучного інтелекту та великих мовних моделей.

Наприклад:

- «Що таке ембедінги та для чого вони потрібні? »
- «Що потрібно знати, щоб зрозуміти, як працюють нейронні мережі? »
- «Як пов'язані токенізація, ембедінги та Transformer? »
- «Як мовна модель визначає, яке слово згенерувати наступним? »
- «Де можна знайти матеріали для вивчення механізму уваги (attention)? »

Основним прикладом використання системи обрано запитання: **«Що таке ембедінги та для чого вони потрібні? »**

Очікується, що асистент пояснить поняття ембедингів простою та зрозумілою мовою, наведе приклади їх використання в AI, зокрема для семантичного пошуку, та надасть посилання на відповідні навчальні матеріали.

Оскільки система також призначена для пояснення зв'язків між поняттями, вона може додатково показати, які знання допоможуть краще зрозуміти тему, наприклад основи векторів і лінійної алгебри, а також які технології пов'язані з ембедингами.

Критерії гарної відповіді

Відповідь асистента вважатиметься гарною, якщо вона:

- Відповідає на запитання. Користувач отримує пояснення саме тієї теми, про яку запитував.
- Є зрозумілою. Складні технічні поняття пояснюються доступною мовою, без зайвого ускладнення.
- Ґрунтується на джерелах. Інформація підтверджується матеріалами з обраного корпусу документів.
- Містить коректні посилання. Користувач може перейти до відповідного документа та самостійно перевірити інформацію.
- Пояснює зв'язки між поняттями. За потреби асистент показує, які знання необхідні для розуміння теми та з якими іншими концепціями вона пов'язана.
- Не вигадує інформацію. Якщо знайдених матеріалів недостатньо, система повідомляє про це.

Критерії поганої відповіді

Відповідь вважатиметься поганою, якщо вона:

- Не відповідає на запитання або містить багато зайвої інформації.
- Використовує складні терміни без пояснень, через що користувачеві важко зрозуміти тему.
- Містить неправильні або непідтверджені твердження.
- Не надає посилань на використані джерела або посилається на матеріали, які не підтверджують відповідь.
- Неправильно визначає зв'язки між поняттями або рекомендує невідповідні теми для попереднього вивчення.
- Надає впевнену відповідь навіть тоді, коли в корпусі немає достатньої інформації.

Таким чином, якість роботи AI Concept Explorer визначатиметься не лише правильністю знайденої інформації, а й тим, наскільки зрозуміло асистент пояснює матеріал, допомагає встановлювати зв'язки між поняттями та дає можливість перевірити відповідь за першоджерелами.

Завдання 2. Вибір та обґрунтування корпусу даних

Для розроблення RAG-системи AI Concept Explorer обрано два відкриті джерела: **Hugging Face Transformers Documentation** та **Hugging Face LLM Course**.

Hugging Face Transformers Documentation містить технічну документацію про архітектури моделей, токенізацію, механізми уваги та використання мовних моделей. Hugging Face LLM Course містить навчальні матеріали, які пояснюють основні поняття та принципи роботи сучасних AI-технологій.

Ці джерела обрано тому, що вони доповнюють одне одного. Навчальний курс допомагає зрозуміти теоретичні основи, а технічна документація дає можливість детальніше розглянути принципи роботи та практичне застосування технологій. Це відповідає основному призначенню AI Concept Explorer — допомагати користувачам вивчати AI та LLM і знаходити пояснення з посиланнями на джерела.

За результатами попереднього аналізу корпус складається з:

- **Hugging Face Transformers Documentation** — 782 файлів у форматі Markdown, джерело: https://github.com/huggingface/transformers, каталог docs/source/en/.
- **Hugging Face LLM Course** — 104 файли у форматі MDX, джерело: https://github.com/huggingface/course, каталог chapters/en/.

Кількість документів визначено за допомогою GitHub REST API шляхом отримання рекурсивного списку файлів відповідних репозиторіїв. Таким чином, загальний попередній обсяг корпусу становить 886 файлів.

Обидва репозиторії використовують ліцензію Apache License 2.0.

Частина технічної документації містить переважно описи програмних інтерфейсів, які можуть бути менш корисними для навчальних пояснень. Тому остаточний склад корпусу буде визначено після перевірки та очищення матеріалів у лабораторній роботі №2.

Завдання 3. Вибір технологічного стеку

Мова програмування — Python. Доцільна для оброблення текстів та інтеграції моделей; має широкий вибір бібліотек для RAG.

Векторне сховище — Chroma. Локальна база, достатня для навчального корпусу; не вимагає окремого сервера.

Модель ембедингів — intfloat/multilingual-e5-small. Попередній вибір багатомовної моделі для українських та англомовних запитів.

Модель генерації — Qwen2.5:3b через Ollama. Попередній вибір локальної моделі, що дає змогу побудувати безкоштовний навчальний прототип без платних API.

Завдання 4. Архітектура запланованої системи

Архітектура передбачає два основні потоки. На етапі підготовки даних документи завантажуються, очищуються, розбиваються на фрагменти та індексуються. Під час відповіді на запит ретривер отримує релевантні фрагменти з індексу, після чого генеративна модель використовує їх як контекст для формування відповіді з посиланнями.



Завдання 5. Організація репозиторію

Публічний репозиторій проєкту: https://github.com/TetianaTrue/rag-project-trukhachova.

Висновок

На етапі проєктування сформульовано цільову аудиторію, головний сценарій використання, приклади запитань, критерії якості та проєктну архітектуру системи.

Декларація використання інструментів ШІ

Під час виконання лабораторної роботи використано ChatGPT (OpenAI, GPT-6) для пояснення теоретичних понять, обговорення архітектури RAG-системи, підготовки та редагування тексту звіту.

Перелік використаних джерел

1. Дашенков Д. С. Методичні вказівки до виконання лабораторних робіт з дисципліни «Технології розробки гібридних систем штучного інтелекту». Харків : ХНУРЕ, 2026.

2. Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS, 2020. URL: https://arxiv.org/abs/2005.11401.

3. Hugging Face. Transformers: офіційний репозиторій. URL: https://github.com/huggingface/transformers.

4. Hugging Face. LLM Course: офіційний репозиторій. URL: https://github.com/huggingface/course.

5. GitHub. REST API: Git Trees. URL: https://docs.github.com/en/rest/git/trees.

6. Chroma. Documentation. URL: https://docs.trychroma.com/.

7. Ollama. Documentation. URL: https://docs.ollama.com/.